

Trabalho Prático 1 - Recuperação de Informação

Henrique Yukio Sekido - NUSP: 14614564; Didrick Chancel Lignina Ndombi – NUSP: 14822368

Instituto de Ciências Matemáticas e de Computação - Universidade de São Paulo

riqueysekido4@usp.br; egninachancel@usp.br

1. Introdução

Este trabalho compara o Modelo Vetorial e o BM25 na recuperação de documentos científicos da coleção Cranfield. Investigam-se os efeitos do pré-processamento, dos parâmetros do BM25 e da reformulação de consultas, combinando avaliação quantitativa e análise de casos para compreender as diferenças entre modelos lexicais.

2. Técnicas Utilizadas

Documentos e consultas são convertidos para minúsculas e tokenizados por expressão regular. Comparam-se quatro configurações: baseline (sem remoção de stopwords ou stemming), remoção de stopwords inglesas, Porter Stemmer e combinação das duas técnicas. Cada documento reúne título e texto.

O Vetorial representa documentos e consultas por TF-IDF, com $TF = 1 + \ln(tf)$ e $IDF = \ln((N + 1)/(df + 1)) + 1$; o score é o produto escalar dividido pelas normas dos vetores. O BM25 calcula explicitamente $IDF \times tf(k1 + 1)/(tf + k1(1 - b + b \cdot dl/avgdl))$ por termo distinto da consulta, com $IDF = \ln(1 + (N - df + 0,5)/(df + 0,5))$. Aqui, N é o número de documentos, df a frequência documental, dl o tamanho do documento e $avgdl$ sua média. $k1$ controla a saturação da frequência e b , a normalização por tamanho.

3. Avaliação

O Cranfield, carregado via `ir_datasets`, contém 1.400 documentos, 225 consultas e 1.837 julgamentos. Todos os experimentos usam essa coleção. Os `qrels` servem à avaliação, sem alterar diretamente os rankings: graus ≥ 1 são relevantes; -1 e documentos não julgados são não relevantes.

Calculam-se $P@10$ (relevantes entre os dez primeiros, divididos por dez), $R@10$ (relevantes recuperados no Top-10 sobre o total relevante) e AP, usando o ranking completo. MAP é a média das APs das 225 consultas. Os resultados são armazenados por consulta e agregados. Os dois modelos usam as quatro configurações; a grade BM25 combina $k1 \in \{0,5; 1,2; 2,0\}$ e $b \in \{0; 0,75; 1\}$ no pré-processamento de maior MAP do BM25 padrão.

4. Resultados e Análise

Na Tabela 1, o BM25 mantém $k1 = 1,2$ e $b = 0,75$. Remover stopwords eleva a MAP de 0,282 para 0,292 no Vetorial e de 0,273 para 0,293 no BM25: a redução de palavras pouco discriminativas também modifica normas e tamanhos dos documentos. O stemming isolado atinge MAP de 0,303 nos dois modelos, compatível com maior correspondência entre variantes morfológicas. Combinadas, as técnicas alcançam 0,311 e 0,320, sugerindo benefícios complementares. Esses ganhos agregados não garantem melhora por consulta: a remoção pode eliminar informação e o stemming pode reunir sentidos distintos.

Tabela 1 - Métricas agregadas por modelo e pré-processamento

Modelo	Pré-processamento	P@10	R@10	MAP
Modelo Vetorial	Baseline	0,223	0,371	0,282
Modelo Vetorial	Stemming	0,240	0,410	0,303
Modelo Vetorial	Stopwords	0,231	0,382	0,292
Modelo Vetorial	Stopwords + stemming	0,243	0,415	0,311
BM25	Baseline	0,227	0,383	0,273
BM25	Stemming	0,231	0,390	0,303
BM25	Stopwords	0,236	0,396	0,293
BM25	Stopwords + stemming	0,238	0,398	0,320

4.1 Análise por consulta

Usa-se remoção de stopwords e stemming nos dois modelos, com $k_1 = 2,0$ e $b = 0,75$ no BM25. A Tabela 2 lista os IDs nas posições 1 a 5, seguidos de R (relevante) ou N (não relevante). Frequências e tamanhos referem-se ao título e texto processados; avgdl = 100,35. Formas como flexibl e nozzl são termos após stemming. Os títulos mantêm a grafia original do corpus.

Tabela 2 - Comparação de consultas e relevância do Top 5

Consulta	AP Vet.	AP BM25	Top 5 Vet.	Top 5 BM25	Caso
205	0,500	0,833	1287 (N); 1321 (R); 55 (N) 1322 (R); 337 (N)	1321 (R); 1287 (N); 1322 (R) 78 (N); 55 (N)	BM25 superior
154	0,500	0,833	832 (N); 1088 (R); 1054 (N) 1087 (R); 1262 (N)	1088 (R); 1054 (N); 1087 (R) 832 (N); 1086 (N)	BM25 superior
168	0,267	0,054	750 (N); 965 (N); 118 (N) 341 (N); 217 (R)	750 (N); 118 (N); 341 (N) 157 (N); 965 (N)	Vetorial superior
144	0,717	0,520	1045 (R); 955 (N); 763 (R) 840 (R); 839 (R)	955 (N); 763 (R); 839 (R) 1363 (N); 1126 (N)	Vetorial superior
22	0,001	0,001	125 (N); 413 (N); 254 (N) 348 (N); 207 (N)	125 (N); 560 (N); 413 (N) 348 (N); 50 (N)	Ambos baixos
31	0,001	0,001	751 (N); 68 (N); 1153 (N) 228 (N); 1245 (N)	751 (N); 1153 (N); 1209 (N) 1245 (N); 228 (N)	Ambos baixos

Nas consultas 205 e 154, o BM25 coloca relevantes nas posições 1 e 3, contra 2 e 4 no Vetorial. Na 205, sobre estabilidade em superfície flexível, 1321 tem 162 termos, cobre seis termos da consulta e repete flexibl oito vezes; 1287 tem 61 termos e cobre quatro. A norma vetorial maior de 1321 (59,00 contra 34,41) atenua seu ganho no cosseno. A combinação de frequência e normalização do BM25 o leva ao primeiro lugar. Na 154, sobre equações elípticas, 1088 cobre os nove termos distintos da consulta; 832 cobre apenas iter, equat e converg, mas concentra-os em 27 termos. Essa concentração favorece o cosseno; a cobertura mais ampla ajuda a explicar a preferência do BM25 por 1088.

Na consulta 168, flow e nozzl aparecem duas vezes e recebem TF sublinear no Vetorial; o BM25 considera cada termo uma vez. O relevante 217 contém cinco ocorrências de flow e seis de nozzl, mas cobre apenas três termos distintos: fica em quinto no Vetorial e em 11º no BM25. Na 144, o relevante 1045 tem 19 termos, com três ocorrências de cylind e pressur, ambos repetidos na consulta. Sua concentração e normalização pelo cosseno ajudam a explicar a primeira posição no Vetorial, contra a sexta no BM25. Neste, 955 lidera com cinco ocorrências de membran e pressur. São hipóteses sustentadas pelos dados, sem isolamento experimental de cada fator.

Nas consultas 22 e 31, P@10 é zero nos dois modelos. Na 22, o primeiro resultado, 125, repete skin e friction nove vezes cada; o único relevante, 68, não compartilha termos processados e recebe score zero. Na 31, 751 cobre sete termos da consulta, incluindo end, plate e bluff; o relevante 776 compartilha apenas two. A escassa correspondência lexical explica a baixa pontuação dos relevantes. Títulos aparentemente próximos ao tema não substituem os qrels.

4.2 Parâmetros do BM25

Tabela 3 - Grade de parâmetros do BM25

k1	b	P@10	MAP
0,5	0,00	0,206	0,279
0,5	0,75	0,224	0,297
0,5	1,00	0,224	0,298
1,2	0,00	0,216	0,291
1,2	0,75	0,238	0,320
1,2	1,00	0,236	0,314
2,0	0,00	0,225	0,298
2,0	0,75	0,244	0,323
2,0	1,00	0,241	0,318

Com b = 0,75, elevar k1 de 0,5 para 1,2 e 2,0 aumenta a MAP de 0,297 para 0,320 e 0,323, e P@10 de 0,224 para 0,238 e 0,244. Um k1 maior retarda a saturação, permitindo maior ganho com repetições: para dl = avgdl e tf = 5, o fator de frequência vale 1,36, 1,77 e 2,14, respectivamente. Isso é compatível com um benefício de valorizar repetições neste corpus, com ganho marginal menor entre 1,2 e 2,0. A tendência também ocorre com b = 0 e b = 1. A melhor combinação testada é k1 = 2,0 e b = 0,75; não se conclui que k1 ainda maior seria melhor.

Mantendo k1 = 2,0 e remoção de stopwords com stemming, b = 0 elimina a normalização por tamanho e b = 1 a aplica integralmente. A Tabela 4 mostra o efeito sobre as métricas e a consulta 72, relativa a interações viscosas em escoamentos com baixo Reynolds e alto Mach.

Tabela 4 - Métricas do BM25 ao variar b com k1 = 2,0

b	P@10	R@10	MAP	Top 5 da consulta 72
0,00	0,225	0,387	0,298	N N N N R
0,75	0,244	0,405	0,323	R N N N R
1,00	0,241	0,405	0,318	R N N R N

Na consulta 72, o primeiro relevante aparece em quinto com $b = 0$; com $b = 0,75$, 630 passa ao primeiro lugar; com $b = 1$, 663 também sobe à quarta posição. A AP cresce de 0,071 para 0,153 e 0,167. Embora $b = 1$ seja melhor nessa consulta, $b = 0,75$ maximiza a MAP da coleção. A normalização muda o ranking, mas sua escolha depende do conjunto, não de um caso isolado.

4.3 Reformulação manual de consultas

As consultas 22, 31, 44, 216 e 13 foram simplificadas para priorizar termos técnicos. As versões usam remoção de stopwords e stemming nos dois modelos e BM25 padrão ($k_1 = 1,2$; $b = 0,75$), distinto da Tabela 2. Os parâmetros permanecem fixos entre original e reformulada, isolando o efeito da alteração textual.

V/B indica Vetorial/BM25. A interseção conta IDs comuns aos Top-10 original e reformulado de cada modelo, independentemente da posição; a última coluna mostra o primeiro ID antes e depois.

Tabela 5 - Consultas reformuladas e mudanças no Top 10

Consulta	Original → reformulada	Relevantes V / B	Interseção V / B	Top 1 antes → depois
22	Original: did anyone else discover that the turbulent skin friction is not over sensitive to the nature of the variation of the viscosity with temperature . Reformulada: turbulent skin friction viscosity temperature relationship	0 → 0 / 0 → 0	7 / 7	V: 125 → 378 B: 125 → 378
31	Original: what size of end plate can be safely used to simulate two-dimensional flow conditions over a bluff cylindrical body of finite aspect ratio . Reformulada: end plate size two-dimensional flow bluff cylindrical body	0 → 0 / 0 → 0	3 / 4	V: 751 → 751 B: 751 → 751
44	Original: what are the details of the rigorous kinetic theory of gases . (chapman-enskog theory) . Reformulada: Chapman Enskog theory kinetic gases	0 → 0 / 0 → 0	6 / 7	V: 1190 → 1190 B: 1190 → 1190
216	Original: what investigations have been made of the wave system created by a static pressure distribution over a liquid surface . Reformulada: wave system static pressure distribution liquid surface	0 → 0 / 0 → 0	5 / 5	V: 175 → 407 B: 693 → 39
13	Original: what is the basic mechanism of the transonic aileron buzz . Reformulada: transonic aileron buzz mechanism	0 → 0 / 0 → 0	9 / 6	V: 496 → 496 B: 496 → 496

Nenhuma reformulação aumenta o número de relevantes no Top-10. Nas consultas 22 e 216, o primeiro resultado muda sem ganho de relevância; nas 31, 44 e 13, ele permanece. Na 13, o documento 496 menciona transonic aileron buzz no título e continua em primeiro, embora não seja relevante segundo os qrels. Seus Top-10 preservam nove documentos no Vetorial e seis no BM25.

A simplificação altera os pesos e a correspondência lexical, mas preserva grande parte do vocabulário técnico. Isso ajuda a explicar a estabilidade de alguns líderes e a ausência de ganho: encurtar a consulta não introduz necessariamente as relações semânticas ou o vocabulário dos documentos julgados relevantes.

4.4 Análise de erros

Com o melhor BM25 (stopwords + stemming, $k_1 = 2,0$; $b = 0,75$), selecionaram-se dois não relevantes em primeiro lugar e um relevante fora do Top-10.

Tabela 6 - Casos selecionados para análise de erros

Caso	Consulta	Documento	Posição	Título do documento
Falso positivo	100	760	1	Inelastic buckling of initially imperfect cylindrical shells subject to axial compression
Falso positivo	103	761	1	Buckling of sandwich under normal pressure
Relevante fora do Top 10	1	879	11	Flutter model testing at transonic speeds

Na consulta 100, 760 compartilha termos sobre cascas cilíndricas imperfeitas e compressão axial, mas trata de flambagem inelástica; a consulta pede flambagem elástica. O modelo lexical não interpreta essa distinção como restrição.

Na consulta 103, buckling e sandwich favorecem 761, mas a consulta exige uma esfera sanduíche e o título recuperado não especifica essa geometria. A correspondência de termos gerais não assegura a relevância para a restrição técnica.

Na consulta 1, o relevante 879 fica em 11°. Seu título aborda testes de flutter em velocidades transônicas, mas não contém similarity laws e heated aircraft. A diferença de vocabulário ajuda a explicar sua posição, apesar da relevância nos qrels.

5. Considerações Finais

Remoção de stopwords e stemming produzem a melhor MAP nos dois modelos. O BM25 com $k_1 = 2,0$ e $b = 0,75$ atinge a maior MAP (0,323), mas o Vetorial vence em algumas consultas. Os exemplos relacionam essas diferenças à cobertura lexical, frequência e normalização. As reformulações não melhoram a relevância no Top-10; os erros evidenciam limitações diante de restrições conceituais e diferenças de vocabulário.

6. Uso de ferramentas de IA

Ferramentas de IA apoiaram a revisão textual, a análise dos resultados, o ajuste do script de comparação e a conferência da especificação. Os resultados vêm dos experimentos do projeto; os integrantes são responsáveis por compreender código, fórmulas e conclusões.